



دانشکده مهندسی کامپیوتر

## تشخیص ناهنجاری با استفاده از یادگیری عمیق

گزارش سمینار کارشناسی ارشد  
در رشته مهندسی کامپیوتر-گرایش هوش مصنوعی و رباتیک

نام دانشجو:  
علی نادری پاریزی

استاد راهنما:  
دکتر محسن سریانی

اردیبهشت ماه ۱۴۰۱

لَهُ مُلْكُ الْأَنْعَمِ الْأَنْجَوِي

## چکیده

تشخیص ناهنجاری مسئله مهمی است که در زمینه‌های تحقیقاتی گوناگون مورد مطالعه قرار می‌گیرد و کاربردهای بسیار زیادی دارد. یک نیاز مرسوم در حوزه تجزیه و تحلیل داده‌های دنیای واقعی، پی بردن به این است که بدانیم کدام نمونه‌ها از نقطه‌نظر تشابه رفتار و ظاهر با اکثریت نمونه‌های موجود بسیار متفاوت هستند. این تفاوت می‌تواند به دلیل خطای اندازه‌گیری در هنگام جمع آوری داده‌ها باشد. گاهی اوقات این تفاوت می‌تواند نشان دهنده وجود پدیده‌ای ناشناخته باشد که در پشت‌پرده جامعه آماری مورد مطالعه در حال رخ دادن است و ما از آن بی‌خبر هستیم.

در علم داده اصطلاح ناهنجاری به داده‌ای تعلق می‌گیرد از نقطه‌نظر یک معیار تشابه تعریف شده، میزان تشابه آن با سایر دادگان موجود بسیار کم باشد. برای مثال اگر عکس رادیولوژی فردی که بیماری ریوی دارد را با عکس‌های رادیولوژی گرفته شده از ریه افراد سالم مقایسه کنیم متوجه تفاوت این عکس با سایر عکس‌ها خواهیم شد. این عدم تشابه در دادگان، مشخص می‌کند که فرد دچار بیماری ریوی است. درواقع پزشکان با مشاهده این عدم شباهت‌ها به وجود بیماری پی می‌برند. عمل مقایسه دادگان می‌تواند به وسیله کامپیوتر نیز انجام شود که موضوع این سمینار است.

در این سمینار تلاش شده روش‌های مبتنی بر یادگیری عمیق برای تشخیص ناهنجاری را بررسی کنیم. از آنجا که کاربرد این موضوع در حوزه‌های مختلف بسیار وسیع است و مقالات بسیار متعددی در رابطه با کاربردهای مختلف به چاپ رسیده، سعی کردیم حوزه سمینار را محدود کرده و ضمن معرفی انواع کاربردهای مسئله تشخیص ناهنجاری، به بررسی روش‌هایی پردازیم که در رابطه با کاربرد پردازش تصویر و بینایی کامپیوتر هستند. با توجه به تعدد مقالات در سال‌های اخیر و وجود مقالات جامع در این حوزه، بیشتر مقالات جدید که در سال‌های اخیر منتشر شده‌اند را بررسی می‌کنیم و برای باقی روش‌ها به ارجاع دهی به مقالات دیگر اکتفا خواهیم کرد.

واژه‌های کلیدی: تشخیص ناهنجاری، پردازش تصویر، شبکه‌های عمیق

# فهرست مطالب

|    |         |   |
|----|---------|---|
| ۱  | ۱       | مقدمه   |
| ۲  | ۱.۱     | مسئله تشخیص ناهنجاری                                    |
| ۳  | ۲.۱     | جنبهای مختلف تشخیص ناهنجاری                             |
| ۳  | ۲.۱.۱   | کاربردهای مسئله تشخیص ناهنجاری                          |
| ۳  | ۲.۱.۱.۱ | امنیت سیستم و تشخیص نفوذ                                |
| ۴  | ۲.۱.۱.۲ | تشخیص جعل استاد و کلاهبرداری                            |
| ۴  | ۲.۱.۱.۳ | سلامت و پزشکی   |
| ۴  | ۲.۱.۱.۴ | سامانه‌های هوشمند و اینترنت اشیا                        |
| ۴  | ۲.۱.۱.۵ | ناظارت ویدیویی و سیستم‌های امنیتی                       |
| ۶  | ۶.۱     | خودروهای خودران   |
| ۶  | ۶.۱.۱   | ساختار کلی روش‌های تشخیص ناهنجاری                       |
| ۷  | ۵.۱     | چالش‌های مسئله تشخیص ناهنجاری                           |
| ۷  | ۶.۱     | ساختار گزارش  |
| ۸  | ۲       | الگوریتم‌های پر استفاده در تشخیص ناهنجاری               |
| ۸  | ۱.۲     | مروری بر روش‌های سنتی                                   |
| ۹  | ۱.۱.۲   | روش‌های مبتنی بر رده‌بندی                               |
| ۱۱ | ۲.۱.۲   | روش‌های مبتنی بر معیار فاصله                            |
| ۱۱ | ۳.۱.۲   | روش‌های مبتنی بر مدل آماری                              |
| ۱۱ | ۲.۲     | مدل‌های یادگیری عمیق پر استفاده در مسئله تشخیص ناهنجاری |
| ۱۲ | ۱.۲.۲   | استفاده از ساختارهای عمیق                               |

|    |                                |       |
|----|--------------------------------|-------|
| ۱۳ | خود رمزگشا                     | ۲.۲.۲ |
| ۱۵ | خود رمزگذار SAE                | ۳.۲.۲ |
| ۱۵ | خود رمز کننده حذف نویز         | ۴.۲.۲ |
| ۱۵ | خود رمز کننده RDA              | ۵.۲.۲ |
| ۱۷ | خود رمز کننده VAE              | ۶.۲.۲ |
| ۱۸ | شبکه های مولد رقابتی (GAN)     | ۷.۲.۲ |
| ۲۰ | مدل های جریانی                 | ۸.۲.۲ |
| ۲۱ | بررسی کارهای انجام شده         | ۳     |
| ۲۲ | کارهای آینده                   | ۴     |
| ۲۲ | مسائل باز و کارهای قابل انجام  | ۱.۴   |
| ۲۲ | موضوع پیشنهادی برای پایان نامه | ۲.۴   |
| ۲۳ | مراجع                          |       |
| ۲۳ | کتاب نامه                      |       |

# فهرست تصاویر

|    |  |      |
|----|--|------|
| ۱  | مثالی از تفاوت دادگان ناهنجار و نوین                               | ۱.۱  |
| ۲  | مثالی ساده از نقاط ناهنجار در مید مجموعه دادهای در فضای دوبعدی [۷] | ۲.۱  |
| ۳  | ناهنجاری نقطه‌ای و دنباله‌ای [۵]                                   | ۳.۱  |
| ۵  | ناهنجاری در کاربرد نظارت ویدیو [۱۳]                                | ۴.۱  |
| ۵  | مثال‌هایی از ناهنجاری در تصاویر [۹]                                | ۵.۱  |
| ۱۰ | ماشین بردار پشتیبان یک کلاسه                                       | ۱.۲  |
| ۱۰ | بردار پشتیبان توصیفگر داده عمیق [۱۹]                               | ۲.۲  |
| ۱۱ | نمایش کلی روش عامل پرت محلی [۴]                                    | ۳.۲  |
| ۱۳ | مدل پرسپترون چند لایه  | ۴.۲  |
| ۱۳ | بردار پشتیبان توصیفگر داده عمیق [۱۹]                               | ۵.۲  |
| ۱۴ | مدل خود رمز کننده  | ۶.۲  |
| ۱۶ | مدل خود رمز کننده حذف نویز   | ۷.۲  |
| ۱۷ | مدل خود رمز کننده variational                                      | ۸.۲  |
| ۱۹ | شبکه مولد رقابتی   | ۹.۲  |
| ۱۹ | نمایش نحوه آموزش مدل F-AnoGan [۲۲]                                 | ۱۰.۲ |

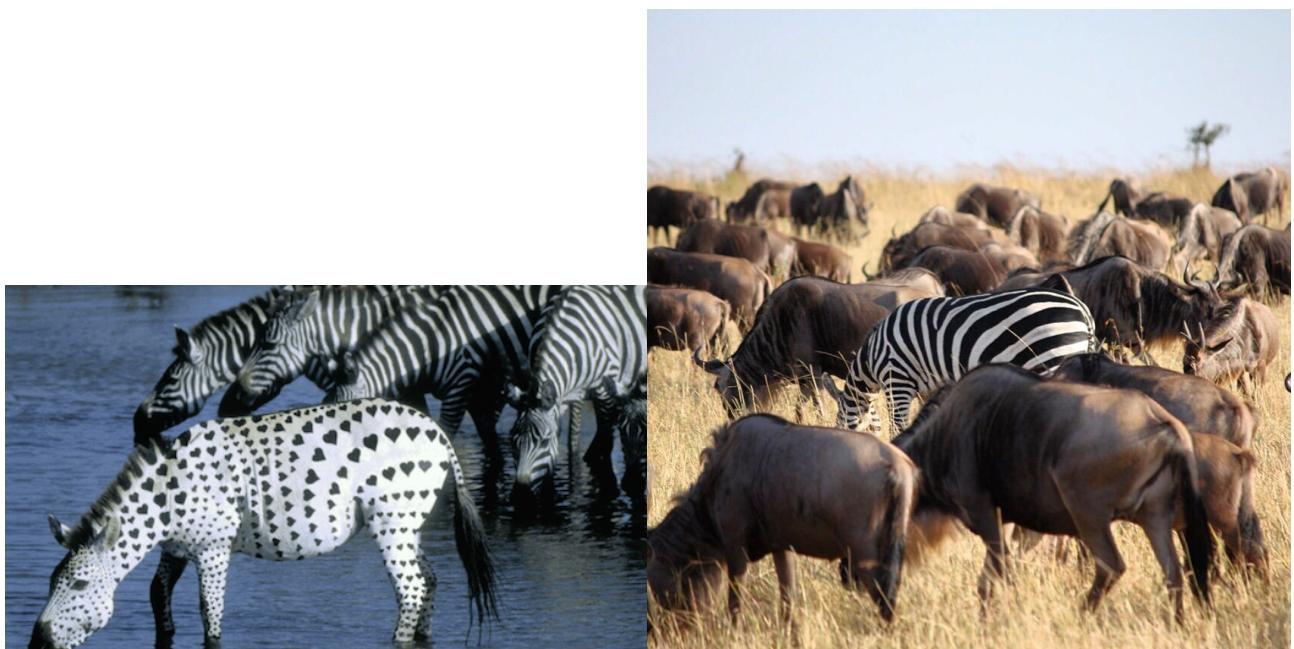
# فهرست جداول

|    |       |  |
|----|-------|--|
| ۹  | ..... | ۱.۲ دسته‌بندی روش‌های سنتی                           |
| ۱۲ | ..... | ۲.۲ الگوریتم‌های عمیق مورد استفاده در تشخیص ناهنجاری |
| ۲۱ | ..... | ۱.۳ الگوریتم‌های عمیق مورد استفاده در تشخیص ناهنجاری |

# فصل ۱

## مقدمه

تشخیص ناهنجاری<sup>۱</sup> مسئله مهمی است که در زمینه‌های تحقیقاتی گوناگون مورد مطالعه قرار می‌گیرد و کاربردهای بسیار زیادی دارد. یک نیاز مرسوم در حوزه تجزیه و تحلیل داده‌های دنیای واقعی، پی بردن این است که بدانیم کدام نمونه‌ها از نقطه نظر تشابه رفتار و ظاهر با اکثریت نمونه‌های موجود بسیار متفاوت هستند. این تفاوت می‌تواند به دلیل خطای اندازه‌گیری در هنگام جمع آوری داده‌ها باشد. گاهی اوقات این تفاوت می‌توانند نشان دهنده وجود پدیده‌ای ناشناخته باشد که در پشت پرده جامعه آماری مورد مطالعه در حال رخ دادن است و ما از آن بی‌خبر هستیم.



شکل ۱.۱: مثالی از تفاوت دادگان ناهنجار و نوین

در کنار ناهنجاری‌ها، دادگان دیگری نیز وجود دارند که با دادگان عادی متفاوت‌اند اما این تفاوت به اندازی کافی زیاد نیست. به این دادگان اصطلاحاً دادگان نوین<sup>۲</sup> گفته می‌شود. دادگان نوین درواقع دادگانی هستند که در دسته دادگان عادی قرار می‌گیرند اما چون هنوز کشف نشده‌اند به نظر می‌رسد که با دادگان عادی تفاوت داشته باشند. برای مثال، اکثر ببرهای دیده شده و شناخته شده به رنگ نارنجی و با خطوط راه راه سیاه هستند و دیدن ببر سفید برای ما تعجب آور خواهد بود. اما همه به خوبی می‌دانیم که ببر سفید درواقع یک ببر است که فقط رنگ آن غیرعادی است و نباید آن را در دسته جدایی

<sup>1</sup>Anomaly detection

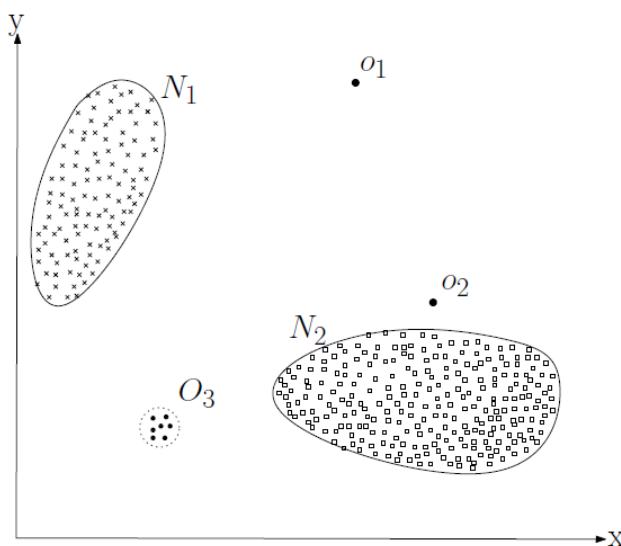
<sup>2</sup>Novelties

از حیوانات قرار داد.

در ادامه این فصل پس از تعریف ناهنجاری در دادگان، به بیان کاربردهای این بحث در حوزه‌های مختلف می‌پردازیم. سپس یک تعریف معیار که مرتبط با حوزه مورد نظر ما که همان پردازش تصویر است ارائه می‌دهیم. پس از تعریف حوزه مورد مطالعه و بررسی اهمیت موضوع، به توضیح ساختار کلی گزارش این سمینار خواهیم پرداخت.

## ۱.۱ مسئله تشخیص ناهنجاری

تشخیص ناهنجاری که با عنوان تشخیص دادگان خارج از محدوده<sup>۳</sup> نیز شناخته می‌شود، به عملیاتی گفته می‌شود که طی آن به آشکارسازی نمونه‌هایی از مجموعه دادگان می‌پردازد که تفاوت زیادی با اکثریت دادگان موجود دارد. در واقع، اینجا تفاوت به معنی متفاوت بودن مشخصات و ویژگی‌های این نمونه‌ها با الگوی معمول موجود در مجموعه دادگان است. این مسئله یک موضوع فعال تحقیق در دهه‌های اخیر بوده. مطالعه برای تشخیص نقاط خارج از دامنه در حوزه آمار به قرن ۱۹ میلادی بر می‌گردد که یکی از مقالات معروف آن مربوط به سال ۱۸۸۷ میلادی است [۱۱]. کاربردهای تشخیص ناهنجاری بسیار وسیع است و در حوزه‌های گوناگونی مورد استفاده قرار می‌گیرد.



شکل ۲.۱: مثالی ساده از نقاط ناهنجار در میاد مجموعه داده‌ای در فضای دوبعدی [۱۱]

ناهنجاری‌ها انواع مختلفی دارند که بسته به کاربرد و مفاهیم مختلف تعریف می‌شوند. به طور کلی می‌توان برای ناهنجاری‌ها سه نوع مختلف درنظر گرفت که عبارت اند از ناهنجاری نقطه‌ای<sup>۴</sup>، ناهنجاری مفهومی<sup>۵</sup>، ناهنجاری مجموعه‌ای<sup>۶</sup>. اکثر کارهای انجام شده در متون علمی در مورد ناهنجاری نقطه‌ای بحث شده است. در این گونه ناهنجاری دادگان به صورت نقاطی در فضا درنظر گرفته می‌شوند و دادگان ناهنجار، نقاطی در فضای مورد نظر هستند که با دیگر دادگان فاصله دارند و رفتاری تصادفی از خود نشان می‌دهند که اغلب تفسیر خاصی ندارند. برا مثال مبلغ بسیار بالای تراکنش در یک رستوران

<sup>3</sup>Outlier detection

<sup>4</sup>Point anomaly

<sup>5</sup>Contextual anomalies

<sup>6</sup>Collective anomalies

یک تراکنش غیر عادی به حساب می‌آید که با در نظر گرفتن آن در فضای بازنمایی دادگان این نقطه شباهتی به دیگر دادگان نخواهد داشت. دسته دوم ناهمجارتی‌های مفهومی هستند که در این دسته مفهوم داده در یک مکان و یا زمان مختلف می‌تواند به صورت ناهمجارتی درنظر گرفته شود. برای مثال عبور وسیله نقلیه در خیابان یک امر طبیعی است اما تردد وسایل نقلیه در مسیر عابرین پیاده یک پدیده غیرعادی است. نوع سوم ناهمجارتی‌ها که اصطلاحاً ناهمجارتی مجموعه‌ای گفته می‌شود، مفهوم ناهمجارتی از در یک سلسله از رویدادها دنبال می‌کند در حالی که هر رویداد یک داده کاملاً عادی است. برای مثال در دنباله تراکنش‌های یک کارت اعتبار وجود چندین تراکنش یکسان با فواصل زمانی بسیار کم مشکوک است.

|        |          |      |             |            |                 |
|--------|----------|------|-------------|------------|-----------------|
| May-22 | 1:14 pm  | FOOD | Monaco Café | \$1,127.80 | → Point Anomaly |
| May-22 | 2:14 pm  | WINE | Wine Bistro | \$28.00    |                 |
| ...    |          |      |             |            |                 |
| Jun-14 | 2:14 pm  | MISC | Mobil Mart  | \$75.00    |                 |
| Jun-14 | 2:05 pm  | MISC | Mobil Mart  | \$75.00    |                 |
| Jun-15 | 2:06 pm  | MISC | Mobil Mart  | \$75.00    |                 |
| Jun-15 | 11:49 pm | MISC | Mobil Mart  | \$75.00    |                 |
| May-28 | 6:14 pm  | WINE | Acton shop  | \$31.00    |                 |
| May-29 | 8:39 pm  | FOOD | Crossroads  | \$128.00   |                 |
| Jun-16 | 11:14 am | MISC | Mobil Mart  | \$75.00    |                 |
| Jun-16 | 11:49 am | MISC | Mobil Mart  | \$75.00    |                 |

شکل ۳.۱: ناهمجارتی نقطه‌ای و دنباله‌ای [۵]

## ۲.۱ جنبه‌های مختلف تشخیص ناهمجارتی

مسئله تشخیص ناهمجارتی را جنبه‌های مختلفی می‌توان مورد بررسی قرار داد. برای مثال می‌توان روش‌های موجود را بر اساس ماهیت دادگان موجود مورد بررسی قرار داد و با توجه به نوع داده انواع روش‌ها را دسته‌بندی کرد. برای نمونه می‌توان ماهیت دادگان را به دو دسته کلی، دنباله‌ای (مانند صدا، موسیقی، فیلم، متن و ...) غیر دنباله‌ای (مانند عکس، مشخصات بیمار و ...) تقسیم کرد. و یا بر اساس تعداد ویژگی‌های داده ورودی به دو دسته ابعاد پایین و ابعاد بالا تقسیم کرد. همچنین می‌توان روش‌های تشخیص ناهمجارتی‌ها را از دید در دسترس بود برچسب دادگان مورد استفاده بررسی کرد. اما باید توجه داشت که پدیده‌های ناهمجارتی اصولاً کم اتفاق می‌افتد و تعداد آنها در دادگان موجود کم است. با این حال می‌توان روش‌های تشخیص ناهمجارتی را از دید رویکرد بر اساس در دسترس بودن برچسب دادگان به سه دسته باناظر، با نظارت ضعیف و همچنین بدون ناظر تقسیم کرد.

## ۳.۱ کاربردهای مسئله تشخیص ناهمجارتی

برای درک اهمیت و کاربرد مسئله تشخیص ناهمجارتی می‌توان به حجم مقالات چاپ شده در این حوزه و دامنه وسیع موضوعات تحقیقاتی اشاره کرد که حول این موضوع انجام شده و یا در حال انجام است. در این قسمت برخی از کاربردهای مسئله تشخیص ناهمجارتی را به تفصیل حوزه‌های کاربردی مختلف می‌آوریم.

### ۱.۳.۱ امنیت سیستم و تشخیص نفوذ

تشخیص نفوذ در کاربرد امنیت سایبری که عمل تشخیص و اطلاع پیدا کردن از دسترسی‌های غیر مجاز به شبکه و یا سامانه‌های رایانه‌ای است می‌تواند یکی از کاربردهای مسئله تشخیص ناهمجارتی باشد. در اینگونه مسائل با بررسی گزارش‌های

سیستم در طول زمان به عنوان داده ورودی به بررسی این قضیه می‌پردازند. همانطور که مشخص است، نوع ناهنجاری در این جا میتواند از دو نوع دنباله‌ای و یا مفهومی باشد.

### ۲.۳.۱ تشخیص جعل اسناد و کلاهبرداری

تشخیص مدارک جعلی در حوزه‌های مختلف مانند هویتی، بانکی، بیمه، کارت اعتباری و غیره بسیار کارآمد است. در اینگونه کاربردها نیز مدارک از جنبه‌های مختلفی با یکدیگر مقایسه می‌شوند تا مدارک جعلی از مدارک حقیقی تشخیص داده شوند. برای مثال، در جعل تراکنش‌های بانکی، میتوان با بررسی تاریخچه تراکنش‌ها، به عنوان داده ورودی، به یافتن تراکنش‌های غیر مجاز و جعلی پرداخت.

### ۳.۳.۱ سلامت و پزشکی

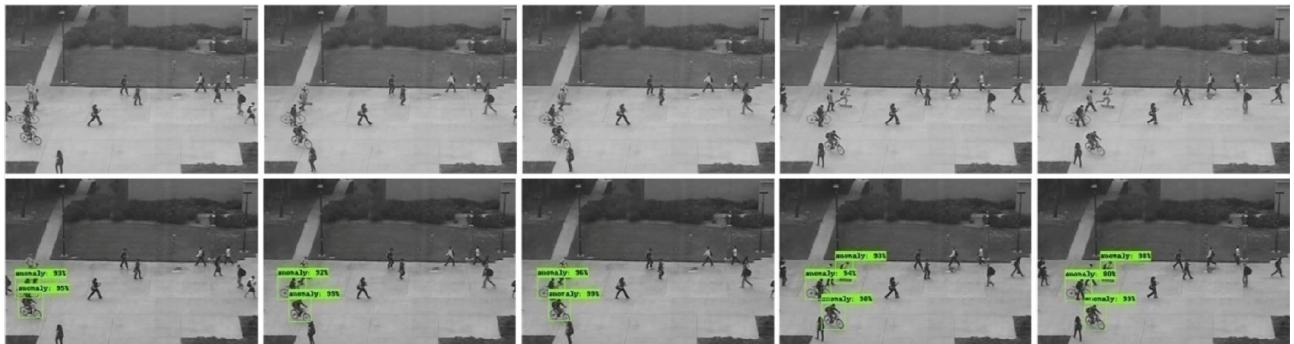
بررسی گزارش‌های پزشکی یک حوزه بسیار فعال در علم کامپیوتر و مهندسی پزشکی بوده است. مقایسه و بررسی این گزارش‌ها از دید مسئله تشخیص ناهنجاری نیز بسیار مورد مطالعه قرار گرفته و کاربردهای فراوانی دارد. برای مثال در بررسی تصاویر پزشکی می‌توان از دید مسئله تشخیص ناهنجاری به یافتن بیماری‌ها و نواقص بیمار و علت بیماری پرداخت. همچنین بررسی گزارش علائم بیمار مانند ظربان قلب، سیگنال‌های مغز، فشار خون و غیره توسط دستگاه‌های پزشکی با هدف آگاهی از شرایط بحرانی و کنترل شرایط بیمار بسیار مناسب است. در این نوع کاربردها دادگان به صورت دنباله‌ای از رویدادها به عنوان داده ورودی مورد بررسی قرار می‌گیرند تا در صورت بروز علائم و شرایط حیاطی غیر طبیعی از پیش‌آمدن اتفاقات ناگوار جلوگیری کنند.

### ۴.۳.۱ سامانه‌های هوشمند و اینترنت اشیا

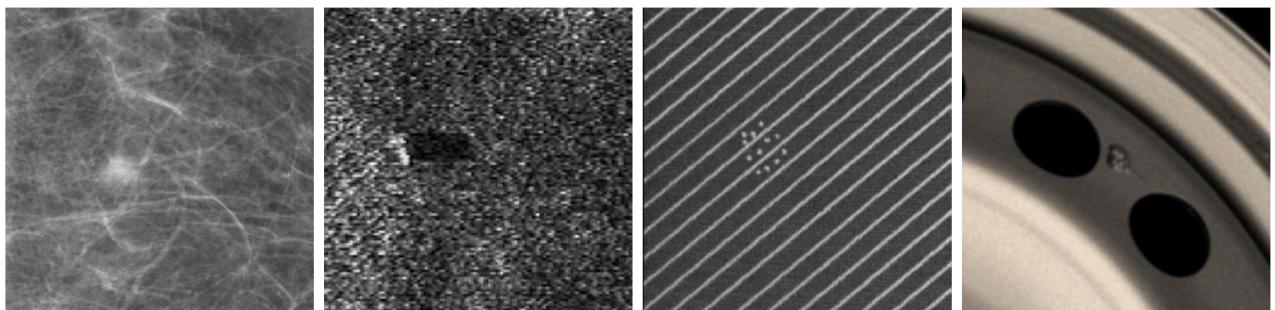
در سیستم‌های خانه هوشمند، سامانه‌های خودکار و اینترنت اشیا معمولاً بسیاری از حسگرهای دستگاهها با استفاده از شبکه‌هایی به هم متصل شده‌اند که برای بررسی وضعیت کلی سیستم و اطمینان از کارکرد صحیح سیستم می‌توان رویدادهای سامانه را در طول زمان مورد بررسی و ارزیابی قرار داد. کاربرد مسئله تشخیص ناهنجاری در اینجا بررسی گزارش‌های سامانه در طی زمان برای پی‌بردن به اتفاق افتادن شرایط نامتعادل و خطاهای سامانه است.

### ۵.۳.۱ نظارت ویدیویی و سیستم‌های امنیتی

دوربین‌های امنیتی در بسیاری از مکان‌ها برای بالابردن امنیت و همچنین نظارت بر افراد و وضعیت کلی مکان مورد استفاده قرار می‌گیرند اما بررسی و نظارت بر فیلم‌های ظبط شده توسط این دوربین‌ها کار بسیار دشوار و وقتی‌گیری است که در مقیاس وسیع این امر نزدیک به غیر ممکن می‌شود. برای مثال نظارت کارآمد دوربین‌های موجود در سطح شهر تهران برای کنترل ترافیک کار بسیار دشواری است و در صورتی که بخواهیم این کار را با استفاده از منابع انسانی انجام دهیم کار وقت و منابع بسیاری را طلب می‌کند. یکی از کاربردهای مسئله تشخیص ناهنجاری در این حوزه بررسی ویدیوها و تلاش برای یافتن پدیده‌های غیر عادی است. برای مثال تشخیص ناهنجاری در تشخیص عبور غیرمجاز وسایل نقلیه، تشخیص تخلف‌های رانندگی، بررسی امنیت مکان‌های عمومی، وضعیت خط تولید کارخانه برای یافتن کالاهای معیوب و کاربردهای دیگری از این قبیل بسیار مورد استفاده قرار می‌گیرد.



شکل ۴.۱: ناهنجاری در کاربرد ناظارت ویدیو [۱۳]



به ترتیب از سمت چپ، توده سرطان سینه، مین زیردریایی، نقص رنگ آمیزی کاشی تولید شده در کارخانه، نمونه نقص موجود در چرخ خودرو.

شکل ۵.۱: مثال‌هایی از ناهنجاری در تصاویر [۹]

## ۶.۳.۱ خودروهای خودران

یکی دیگر از حوزه‌های بسیار پرطرفدار در سال‌های اخیر ساخت خودروهای خودران و رانندگی خودکار وسایل نقلیه مختلف است. در این گونه سسیتم‌ها نیز می‌توان با بررسی وضعیت حسگرها و دوربین‌های نصب شده بر روی وسیله نقلیه به بررسی خطرات احتمالی و شرایط غیرعادی مسیر درحال عبور پرداخت. با توجه به اینکه شرایط غیر عادی در رانندگی که منجر به تصادف و خطر شود به ندرت اتفاق می‌افتد و همچنین این شرایط می‌توانند به صورت‌ها و شکل‌ها مختلف روی دهنده، استفاده از روش‌های تشخیص ناهنجاری در این کاربردها بسیار مورد پسند پژوهشگران این حوزه قرار گرفته است.

### ۴.۱ ساختار کلی روش‌های تشخیص ناهنجاری

اگر بخواهیم روش‌های تشخیص ناهنجاری را به صورت عمومی توصیف کنیم، می‌توانیم بگوییم که این روش‌ها عموماً دارای سه مرحله اصلی هستند. مرحله اول یادگیری بازنمایی داده‌ها<sup>۵</sup> است. در این مرحله نگاشتی از دادگان ورودی به فضای معین آموخته می‌شود. این نگاشت را می‌توان به صورت تابعی مانند زیر تعریف کرد.

$$f(\cdot; \theta) : x \rightarrow y \quad (1.1)$$

در مرحله دوم به تعریف یک معیار سنجش برای ارزیابی خروجی مرحله قبل پرداخته می‌شود. این معیار که به صورت یک تابع بیان می‌شود با دریافت خروجی مرحله قبلی عددی را به عنوان یک امتیاز برای سنجش میزان تعلق داده ورودی به دسته ناهنجار اختصاص می‌دهد که به آن امتیاز ناهنجاری<sup>۶</sup> گوییم.

$$d(f(x); \eta) : f(x) \rightarrow d, \quad d \in \mathbb{R} \quad (2.1)$$

در آخر نیز با درنظر گرفتن یک مقدار آستانه  $\delta$ ، به تصمیم‌گیری در مورد داده ورودی با توجه به امتیاز اختصاص داده شده در مرحله دوم پرداخته می‌شود.

$$g(d(f(x))) = \begin{cases} \text{anomaly} & d \geq \delta \\ \text{not anomaly} & d < \delta \end{cases} \quad (3.1)$$

با توجه به این تعریف، رویکردهای موجود می‌توانند انواع زیر را داشته باشند:

۱. غیر پارامتری: نیازی به یادگیری  $\theta$  و  $\eta$  و  $\delta$  نیست.

۲. یک مرحله‌ای: تنها یکی از مجموعه پارامترهای موجود  $\theta$  یا  $\eta$  یادگرفته می‌شوند.

۳. دو مرحله‌ای: هر دو مجموعه پارامتر  $\theta$  و  $\eta$  به صورت مستقل و جداگانه یادگرفته می‌شوند.

۴. ادغامی<sup>۹</sup>: هر دو مجموعه پارامتر  $\theta$  و  $\eta$  باهم یادگرفته می‌شوند.

<sup>7</sup>Data representation

<sup>8</sup>Anomaly score

<sup>9</sup>Integrated

در صورت عدم وجود برچسب‌های دادگان موجود، ناچار به استفاده از روش بدون ناظر هستیم که در آن از هیچ گونه اطلاعاتی در مورد ماهیت دادگان در دسترس نیست. در این موقع معمولاً از پیش تعریف شده است و یا همراه با ۶۶ یادگرفته می‌شود.

در حالتی که تنها بخشی از دادگان برچسب خورده باشند و باقی برچسب نخورده، می‌توان از رویکرد یادگیری با نظارت ضعیف استفاده کرد. در این مورد نیز مقدار آستانه می‌تواند با استفاده از تنظیم دقیق مدل بدست آید.

## ۵.۱ چالش‌های مسئله تشخیص ناهنجاری

یکی از مهم ترین چالش‌های موجود در مسائل تشخیص ناهنجاری در دسترس نبودن دادگان برچسب خورده ناهنجار است. در اکثر مواقع برچسب دادگان ناهنجار توسط افراد متخصص ایجاد می‌شوند و این امر بسیار هزینه بر است. در صورت وجود داشتن برچسب دادگان ناهنجار، بدلیل اینکه عموماً اینگونه دادگان، دادگان نادری هستند و احتمال اتفاق افتادن آنها بسیار کم است، در یک مجموعه داده تعداد دادگان ناهنجار نسبت به سایر دادگان بسیار کمتر خواهد بود و این مسئله در بکارگیری روش‌های باناظر، اشکالاتی را ایجاد می‌کند. چالش دیگر نیاز به یادگیری الگوی دادگان عادی در ابعاد بالا است. برای اینکه بتوانیم دادگان ناهنجار را از سایر دادگان تشخیص دهیم نیاز است اطلاعات زیادی از دادگان را به عنوان ویژگی‌ها مورد بررسی قرار دهیم. و این امر باعث می‌شود تا نیاز به یادگیری توزیع دادگان در ابعاد بالا داشته باشیم. همچنین تعریف دادگان ناهنجار در کاربردهای گوناگون متفاوت است و این امر باعث می‌شود تا ما به خوبی نتوانیم یک روش عمومی برای این امر معرفی کنیم و مرز میان دادگان عادی و ناهنجار معمولاً نامشخص است. در برخی مواقع دادگان به صورت مستقل از یکدیگر توزیع نشده اند و فرض D.I.I. بودن دادگان برقرار نیست. برقرار نبودن این مورد که یک فرض پایه‌ای در بسیاری از روش‌های یادگیری است ما را در استفاده از روش‌های مرسوم یادگیری دچار مشکلاتی خواهد کرد. این مسئله در مورد ناهنجاری‌های از نوع مفهومی و دنباله‌ای مطرح می‌شود که نقاط ناهنجار با توجه به وابستگی آن‌ها با نقاط اطراف مشخص می‌شوند و معنی ناهنجاری را به خود اختصاص می‌دهند.

## ۶.۱ ساختار گزارش

در فصل اول این سمینار به معرفی حوزه سمینار و تعریف مسئله تشخیص ناهنجاری و کاربردهای آن در حوزه‌های مختلف پرداخته شد. در فصل دوم به معرفی پیش‌نیازها و الگوریتم‌های پایه و پر استفاده در روش‌های تشخیص ناهنجاری پرداخته می‌شود. فصل سوم نیز با بررسی روش‌های عمیق مورد استفاده در مقالات روز و معرفی کارهای مرتبط با این سمینار به بررسی جزئی از روش‌ها و مقالات موجود چاپ شده در سال‌های اخیر خواهد پرداخت. در نهایت، در فصل چهارم، مسائل باز و کارهای آینده این حوزه معرفی شده و چند نمونه پیشنهاد برای پروژه نهایی مطرح خواهد شد.

## فصل ۲

### الگوریتم‌های پر استفاده در تشخیص ناهنجاری

برای درک بهتر مقالات و پژوهش‌های انجام شده با موضوع تشخیص ناهنجاری، خوب است ابتدا مروری بر ساختارهای کلی موجود که در روش‌های تشخیص ناهنجاری استفاده می‌شوند داشته باشیم. اینگونه روشها پایه و اساس بسیاری از مقالات روز هستند و شناختن مدل و نحوه کارکرد مدل ما را در درک بهتر ایده نویسندگان مقالات و هدف از استفاده از این روش‌ها در کارهای انجام شده کمک می‌کند. مطالعه روش‌های پایه کمک میکند تا کارهای انجام شده اخیر را که در فصل بعد مورد بررسی قرار گرفته‌اند بهتر درک بشوند.

این فصل شامل دو بخش اصلی است که در بخش اول به معرفی روش‌های سنتی پرداخته می‌شود. هدف از آوردن روش‌های سنتی آشنایی پایه‌ای با مسئله تشخیص ناهنجاری است و همچنین این روش‌ها میتوانند با ترکیب شدن با روش‌های عمیق، مدل‌های جدیدی را بسازند و همچنین ایده به وجود آوردن مدل‌های عمیق دیگر باشند. در بخش دوم روش‌های عمیق مورد استفاده در مسئله تشخیص ناهنجاری آورده شده‌اند که مطالعه این روش‌ها برای درک مطالب فصل بعدی ضروری است.

#### ۱.۲ مروری بر روش‌های سنتی

اگر به یاد داشته باشید، در ابتدای فصل یک به این نکته اشاره شد که مسئله تشخیص ناهنجاری، یک موضوع فعل تحقیق در چند دهه اخیر است که یکی از مقالات معتبر چاپ شده آن مربوط به دهه ۱۹۶۰ میلادی می‌شود. از این رو، در طی این مدت بسیاری از روش‌ها برای یافتن دادگان خارج از محدوده معرفی و توسعه داده شده‌اند که از یادگیری عمیق استفاده نمی‌کنند. این روش‌ها به صورت عمده دادگان را مجموعه‌ای از نقاط در یک فضای چند بعدی فرض می‌کنند و تلاش آنها برای این است که نقاط خارج از محدوده را با توجه به ویژگی‌ها و مشخصات نقاط دیگر آشکار کنند. عمدتاً این اینگونه روش‌ها را می‌توان از نقطه‌نظر ایده اصلی به سه دسته کلی تقسیم کرد که عبارت‌اند از: استفاده از رده‌بندی، مبتنی بر معیار فاصله و استفاده از مدل‌های آماری<sup>۱</sup>. در ادامه به مرور کلی این روش‌ها خواهیم پرداخت. با توجه به اینکه تمرکز ما بر بررسی کامل این روش‌ها نیست پیشنهاد می‌شود برای آشنایی بیشتر با این‌گونه روش‌ها به مقاله چاندولا و همکاران مراجعه کنید [۷].

<sup>۱</sup> ر.ک جدول ۱.۲

| دسته‌بندی روش‌های سنتی در تشخیص ناهنجاری |   |  |             |
|--|---|--|-------------|
| روش‌های شناخته شده                       | انواع   | خلاصه ایده   | رویکرد      |
| One-class SVM<br>SVDD                    | یک کلاسه  | یادگیری یک مرز تفکیک میان دادگان عادی و ناهنجار                                  | رده‌بندی    |
| -  | چند کلاسه   |  |             |
| LOC <sup>2</sup><br>COF                  | فاصله تا نزدیک ترین همسایه                        | اقدام به تعریف یک معیار فاصله می‌کند تا دادگان عادی را از دادگان ناهنجار جدا کند | معیار فاصله |
| K-means<br>CBLOF                         | خوشه‌بندی و سنجش فاصله تا نزدیک ترین خوشه         |  |             |
| PCA<br>Isolation Forest                  | استفاده از تصویر سازی نقاط در فضایی با ابعاد کمتر |  |             |
| Gaussian Mixture Model                   | روش‌های پارامتری                                  | دادگان عادی در نواحی پر احتمال مدل آماری قرار می‌گیرند                           | مدل آماری   |
| Kernel destiny estimator                 | روش‌های غیر پارامتری                              |  |             |

جدول ۱.۲: دسته‌بندی روش‌های سنتی

## ۱.۱.۲ روش‌های مبتنی بر رده‌بندی

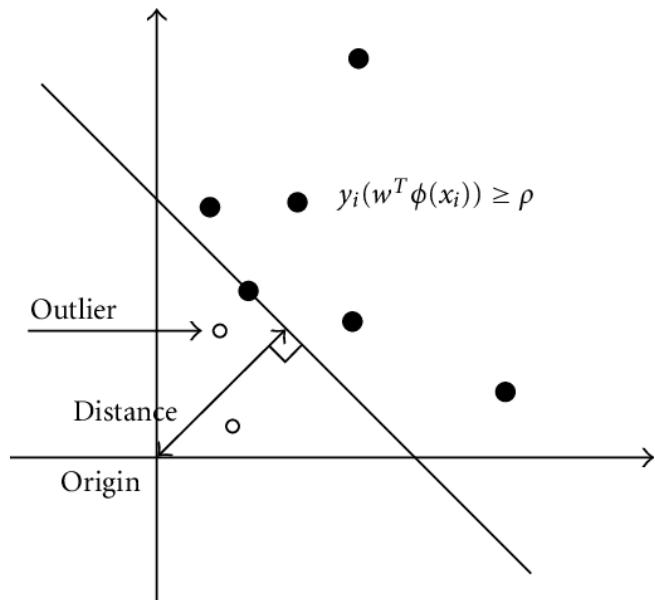
همانطور که در ابتدای این بخش گفته شد، یکی از ایده‌های کلی در روش‌های مورد استفاده برای تشخیص ناهنجاری استفاده از ایده رده‌بندی است. در اینگونه روش‌ها تلاش می‌شود یک مرز تفکیک میان دادگان عادی و دادگان ناهنجار رسم شود. اگر چنین مرزی وجود داشته باشد، می‌توان با استفاده از الگوریتم‌های رده‌بند موجود اقدام به یافتن این مرز و آشکارسازی داده‌های ناهنجار کرد. همانطور که مشخص است در اینگونه روش‌ها تنها یک دسته برای دادگان تعريف می‌شود که آن دسته دادگان عادی است. دیگر دادگانی که در این دسته قرار نمی‌گیرند به عنوان دادگان عادی در نظر گرفته می‌شوند. البته استفاده از رویکرد رده‌بندی چند کلاسه نیز در صورت وجود برچسب برای تمامی دادگان امکان پذیر است اما استفاده از این روش کمتر مرسوم است. یکی از معروف ترین روش‌های مورد استفاده دسته بند، ماشین بردار پشتیبان یک کلاسه<sup>۳</sup> است. در روش ماشین بردار پشتیبان که در یک روش معروف رده‌بندی است تلاش می‌شود دادگان دو دسته موجود توسط یک صفحه از یکدیگر جدا شوند. در الگوریتم بردار پشتیبان یک کلاسه سعی می‌شود صفحه جدا کننده را طوری مشخص کند تا دادگان معمول در یک طرف این صفحه و دادگان ناهنجار در سمت دیگر آن قرار گیرند. همچنین تلاش می‌شود صفحه مورد نظر تا حد امکان به نقاط داده عادی نزدیک باشد. پس از رسم این صفحه، دادگانی که به مبدأ مختصات نزدیک تر هستند در دسته ناهنجاری‌ها قرار می‌گیرند [۲۴].

در اینجا تابع نگاشتی که باید یاد گرفته شود همان تابع کرنل در ماشین بردار پشتیبان است و تابع امتیاز ناهنجاری نیز به صورت اندازه فاصله از مبدأ مختصات تعريف می‌شود. شکل ۱.۲ این روش را به تصویر کشیده است. توجه داشته باشید که در اینجا تنها یک دسته برای رده‌بندی تعريف می‌شود که آن دسته دادگان عادی است، پس نیازی به وجود برچسب برای تمامی دادگان نیست و این رویکرد به صورت کاملاً بدون ناظر خواهد بود.

نمونه دیگری از روش‌های مورد استفاده برای آشکارسازی ناهنجاری که از رویکرد رده‌بندی استفاده می‌کند، بردار پشتیبان توصیفگر داده<sup>۴</sup> است. در این روش سعی می‌شود کره‌ای با کوچک ترین اندازه شعاع ممکن حول دادگان موجور رسم شود.

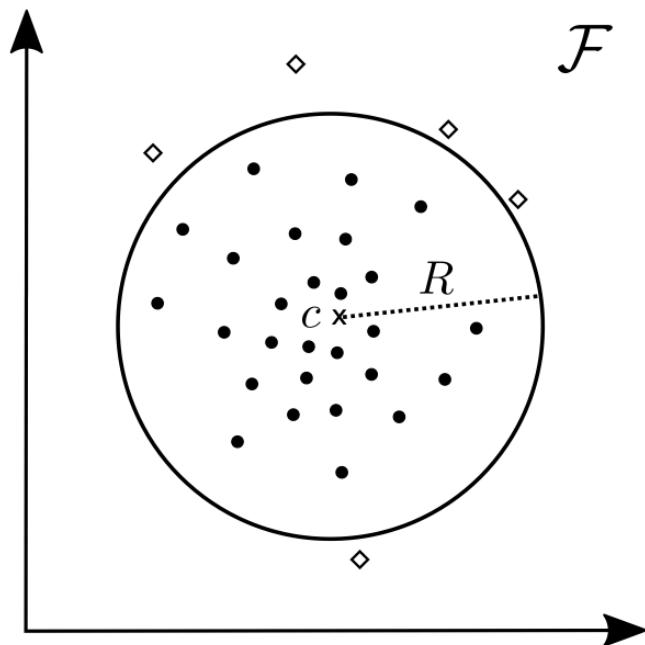
<sup>3</sup>One-class SVM

<sup>4</sup>Support Vector Data Description (SVDD)



شکل ۱.۲: ماشین بردار پشتیبان یک کلاسه

پس از رسم این کره، دادگانی که در خارج از آن قرار می‌گیرند به عنوان داده ناهمجارت شناخته خواهند شد [۱۹].

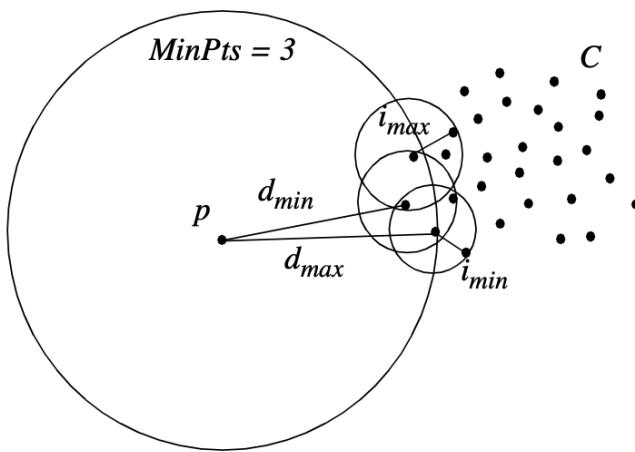


شکل ۲.۲: بردار پشتیبان توصیفگر داده عمیق [۱۹]

از جمله مزیت‌های این رویکرد، آموزش سریع، و دقیق بیشتر آن در موقعی است که دادگان برچسب خورده در اختیار هستند. و از معایب این روش در هنگام استفاده از رده‌بندی چند کلاسه می‌توان به نیاز برای چندین دسته داده عادی یاد کرد. همچنین این رویکردها نیاز به تعیین ابرپارامتر برای مدل یادگیری دارند.

## ۲.۱.۲ روش‌های مبتنی بر معیار فاصله

اگر به دادگان موجود را به صورت نقاطی بازنمایی شده بر روی صفحه مختصات نگاه کنیم، می‌توانیم از معیار فاصله نقاط از یکدیگر به تصمیم‌گیری در مورد دادگان بپردازیم. در اینگونه رویکردها معمولاً اقدام به تعریف یک معیار فاصله می‌کنند تا دادگان عادی را از دادگان ناهمجارتان بفرمایند. یک نمونه روش معروف که در این دسته می‌گنجد روش معروف عامل پرت محلی<sup>۵</sup> است. در این روش میانگین فاصله هر نقطه از همسایگان محلی محاسبه شده و اگر این میانگین از یک مقدار آستانه محلی<sup>۶</sup> بیشتر باشد، داده به عنوان داده ناهمجارتان شناخته می‌شود. برای سادگی کار، میانگین فاصله نقطه تا تمام همسایگان را بر میانگین فاصله میان همسایگان نقطه محاسبه شده و مقدار آستانه برابر با عدد یک درنظر گرفته می‌شود [۴]. در استفاده از این روش نیز نیازی به وجود برچسب دادگان نیست همچنین این روش پارامتری برای یادگیری ندارد و در دسته روش‌های بدون پارامتر نیز قرار می‌گیرد. در واقع این گونه روش‌ها معمولاً به صورت بدون ناظر هستند.



شکل ۳.۲: نمایش کلی روش عامل پرت محلی [۴]

## ۳.۱.۲ روش‌های مبتنی بر مدل آماری

ایده اصلی در این دسته از رویکردها بدین صورت است که، دادگان عادی همواره احتمال رخداد بالایی دارند، در نتیجه در نواحی از مدل آماری قرار می‌گیرند که احتمال وقوع آنها بیشتر است. برای مثال در روش مدل خطی پویا<sup>۵</sup> ابتدا دادگان را از فضای ورودی به یک فضای از پیش تعیین شده نگاشتند می‌کنیم. سپس با استفاده از مدل بدست آمده سعی در پیش‌بینی مقدار ورودی با توجه به دیگر دادگان موجود می‌کنیم. در اینجا امتیاز ناهمجارتی میزان تفاوت مقدار پیش‌بینی شده و مقدار حقیقی داده است. اگر مقدار اختلاف از یک مقدار آستانه از پیش تعیین شده، که با استفاده از آزمایش با دادگان برچسب خورده بدست آمده، بیشتر باشد، به دسته دادگان ناهمجارتان تعلق می‌گیرد.

## ۲.۲ مدل‌های یادگیری عمیق پر استفاده در مسئله تشخیص ناهمجارتی

در بخش قبلی با روش‌های سنتی پر استفاده در مسئله تشخیص ناهمجارتی آشنا شدیم. در این بخش به معرفی مدل‌های یادگیری عمیق پر استفاده در اینگونه مسائله پرداخته می‌شود که پایه و اساس خیلی از روش‌های ارائه شده در مقالات هستند

<sup>۵</sup>Local Outlier Factor

<sup>۶</sup>Dynamic liner model

و آشنایی با آنها به درک بهتر مطلب کمک بسیار زیادی خواهد کرد. پس از معرفی ساختار مورد بحث نمونه‌هایی از کارهای انجام شده که از آن استفاده می‌کنند را به اختصار معرفی خواهیم کرد. جدول ۲.۲ لیستی از روش‌های مورد بحث در این بخش را جمع آوری کرده است.

جدول ۲.۲: الگوریتم‌های عمیق مورد استفاده در تشخیص ناهنجاری

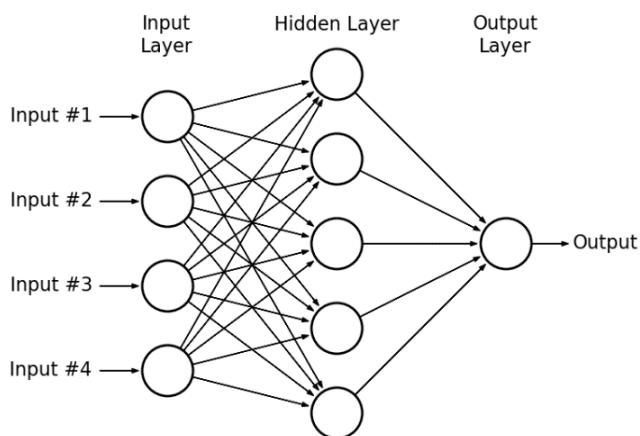
| نام مدل | مقاله مرجع | مزیت استفاده  |
|---------|------------|---|
| AE      |            | عدم نیاز به برچسب دادگان  |
| SAE     |            | درنظر گرفتن ابعاد بالاتر در لایه میانی برای در نظر گرفتن ویژگی‌های بیشتری از دادگان |
| DAE     |            | کاهش حساسیت مدل به نویز موجود در دادگان   |
| RDA     |            | استفاده از دادگان ناهنجار در طی فرآیند یادگیری                                      |
| VAE     |            | نگاشت دادگان به یک توزیع احتمال بجای یادگیری نگاشت بدون پایه و اساس در لایه میانی   |
| DCAE    |            |   |
| DTS     |            |   |
| GAN     |            |   |

## ۱.۲.۲ استفاده از ساختارهای عمیق

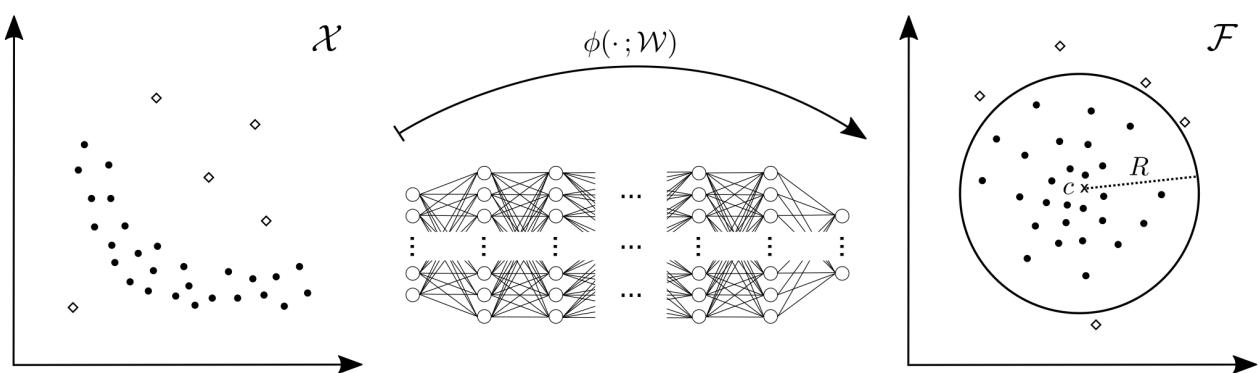
یکی از ابتدایی ترین ایده‌هایی که در مورد استفاده از روش‌های سنتی موجود با توجه به معرفی و پیشرفت ساختارهای عمیق به ذهن می‌رسد، استفاده از این ساختارها در روش‌های سنتی است. ساختارهای عمیق با توجه به قابلیت بالای یادگیری ترکیب‌های غیر خطی گوناگون، می‌توانند به عنوان تابع نگاشت دادگان در روش‌های سنتی استفاده شوند تا بتوانند بازنمایی بسیار بهتری از دادگان را برای انجام عملیات امتیازدهی و تشخیص ناهنجاری بدست آورند. مدل پرسپترون چند لایه‌ای<sup>۷</sup> یکی از ابتدایی ترین و مهم‌ترین مدل‌هایی است که می‌توان آنرا نقطه شروعی بر تمام روش‌های عمیق موجود در حال حاضر دانست. این مدل درواقع شبکه‌ای از نورون‌های عصبی مصنوعی<sup>۸</sup> است که لایه‌های آن صورت کاملاً متصل با یکدیگر ارتباط دارند. این شبکه دارای حداقل سه لایه ورودی، مخفی و خروجی است که در آن به غیر از نورون‌های لایه ورودی، باقی نورون‌ها دارای تابع فعال سازی غیر خطی هستند. این مدل برای یادگیری بازنمایی غیر خطی دادگان ورودی معرفی شده و در بسیاری از روش‌های تشخیص ناهنجاری کاربرد دارد. برای مثال در روش بردار پشتیبان توصیفگر داده که در فصل دوم معرفی شد می‌توان بجای تابع  $f(\theta; \cdot)$  که مسئول نگاشت دادگان به فضایی معین برای بدست آورد بازنمایی خوبی از دادگان است از یک شبکه عمیق مانند مدل پرسپترون چندلایه استفاده کرد. این مدل به دلیل توانایی یادگیری نگاشت غیر خطی دادگان می‌تواند بازنمایی بهتری از دادگان را برای مرحله دوم محاسبات که همان عمل امتیاز دهی به نقاط است بدست آورد. راف و همکاران با استفاده از این ایده، روش بردار پشتیبان توصیفگر داده عمیق را معرفی کردن که در مقایسه با روش‌های سنتی عملکرد بسیار بهتری را از خود نشان داده است [۱۹]. این روش در مقایسه با برخی روش‌های عمیق نیز نتایج بسیار مطلوبی را دربر داشته است که در بخش مقایسه روش‌ها این نتایج آورده خواهند شد.

<sup>7</sup>Multilayer Perceptron

<sup>8</sup>Perceptron



شکل ۴.۲: مدل پرسپترون چند لایه



شکل ۵.۲: بردار پشتیبان توصیفگر داده عمیق [۱۹]

## ۲.۲.۲ خود رمزگشا

خودرمز گشا<sup>۹</sup>‌ها نوعی از شبکه‌های عصبی هستند که از روش پس انتشار<sup>۱۰</sup> برای یادگیری ویژگی‌های مفهومی استفاده می‌کنند. این شبکه‌ها به صورت دو مرحله‌ای اقدام به یادگیری می‌کنند که به ترتیب رمزگاری و رمزگشایی نام دارند. در مرحله اول داده ورودی به شبکه رمز کنند داده می‌شود و رمز کننده داده ورودی را به یک فضای با ابعاد پایین نگاشت می‌کند. به این فضای باقی‌مانده<sup>۱۱</sup> یا فضای z می‌گویند. در مرحله دوم، بازنمایی بددست آمده وارد شبکه رمزگشا شده تا داده از فضای باقی‌مانده دوباره به فضای ورودی باز گردانده شود. آنچه که انتظار می‌رود آن است که خروجی مدل با آنچه در ورودی به مدل داده شده بسیار شبیه باشند. در این صورت قسمت رمز کنند توانسته بازنمایی خوبی از داده را در فضای باقی‌مانده ایجاد کند [۳].

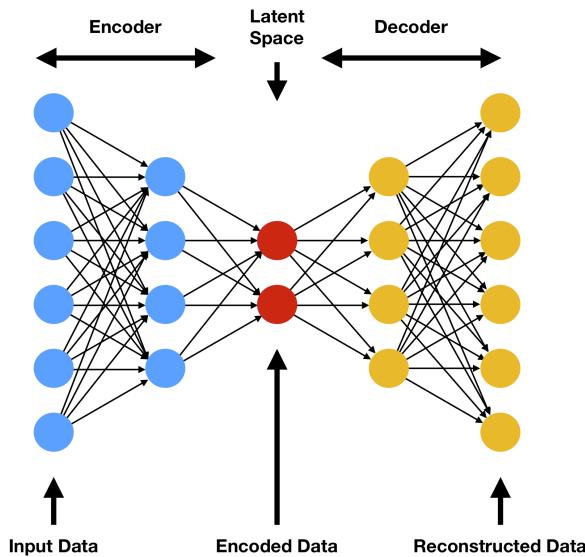
اگر بخواهیم کارکرد مدل شکل ۶.۲ را با فرمول ریاضی توصیف کنیم، با در نظر داده  $X$  به عنوان ورودی مدل، رمز کنند با گرفتن این ورودی، آن را به فضای باقی‌مانده و به نقطه z نگاشت می‌کند. اگر تابع رمز کننده را  $f$  بنامیم معادله مرحله اول به صورت زیر خواهد بود.

$$f(X, \theta_1) : X \rightarrow z \quad (1.2)$$

<sup>9</sup>AutoEncoder

<sup>10</sup>Backpropagation

<sup>11</sup>Latent space



شکل ۲.۶: مدل خود رمز کننده

که در اینجا ابعاد فضای  $z$  از ابعاد فضای ورودی  $X$  کمتر است. این بدان معنی است که در اینجا عمل کاهش ابعاد ورودی صورت گرفته است. اگر رمزگشا را مانند تابعی در نظر بگیریم و آن را  $g$  بنامیم، این تابع با دریافت ورودی  $z$ ، اقدام به بازسازی داده ورودی می‌کند.

$$g(z, \theta_2) : z \rightarrow \hat{X} \quad (2.2)$$

در کاربردهای تشخیص ناهنجاری معمولاً در هنگام استفاده از این معماری، سعی می‌شود از تابع خطای مقایسه ورودی و خروجی مدل برای آموزش مدل استفاده کنند و در فرایند آموزش تنها از دادگان عادی استفاده شود. ایده اصلی در این گونه روش‌ها این است که با توجه به اینکه مدل تنها با دادگان عادی آموزش دیده است، دادگانی که توسط این مدل نتوانند به خوبی بازسازی شوند دارای ناهنجاری بوده‌اند. در واقع در اینجا تابع خطای همان تابع امتیاز ناهنجاری است به صورت زیر تعریف می‌شود.

$$L(X, g(f(x))) = d \quad (3.2)$$

پس از آموزش مدل مقدار آستانه  $\delta$  برای بدست آوردن بهترین نتیجه با آزمون و خطای خطا و یا روش‌های دیگر مانند استفاده از نمودار حساسیت و دقت تعیین می‌شود.

خودرمز کننده‌ها باید به تغییرات دادگان ورودی حساس باشند تا بتوانند با دقت مطلوب داده رمز شده را بازسازی کنند. همچنین این حساسیت نباید به اندازه‌ای باشد که باعث بشود مدل بجای یادگیری عملکرد مناسب، به بخار سپاری دادگان ورودی پردازد و دچار بیش‌برازش<sup>۱۲</sup> بشود. برای دستیابی به چنین توازنی، انواع مختلفی از خودرمز کننده‌ها معرفی شده‌اند که با افزودن یک مقدار تنظیم کننده<sup>۱۳</sup> به تابع خطای اصلی معرفی شده، بدست می‌آیند.

$$L(X, g(f(X))) + \text{regulizer} \quad (4.2)$$

<sup>12</sup>Overfit

<sup>13</sup>Regulizer

## ۳.۲.۲ خود رمزگذار SAE

خود رمز کننده<sup>۱۴</sup> SAE یکی از انواع خودرمز کننده‌ها است. ایده اصلی این گونه رمز کننده‌ها این است که، با توجه به اینکه تعداد نورون‌ها لایه مخفی به اندازه کافی زیاد نباشند شاید نتوانند به خوبی مفاهیم پیچیده را یاد بگیرند. در نتیجه پیشنهاد می‌شود در لایه مخفی تعداد نورون‌های بیشتری قرار گیرند اما از تابع فعال سازی ترتیبی داده شود تا این نورون‌ها تاحد ممکن کم استفاده شوند و یا به اصطلاح، به صورت خلوت<sup>۱۵</sup> فعال سازی آنها صورت بگیرید. برای دستیابی به چنین هدفی می‌توان از تنظیم کنند<sup>۱۶</sup> در تابع خطای مدل استفاده کرد. نوع اول استفاده از تنظیم کننده نرم یک است<sup>۱۷</sup> که معادله تابع خطا به صورت زیر خواهد بود.

$$L(X, g(f(X))) + \lambda \sum_i^n |a^{(h)}| \quad (5.2)$$

با استفاده از این نوع تنظیم کننده، چون تابع نرم یک استفاده شده، در طی فرایند یادگیری سعی می‌شود وزن یال‌های متصل به نورنوها تاجای امکان صفر باشد و با صفر شدن این وزن‌ها، درواقع نورون‌های کمتری در فرایند محاسبه استفاده می‌شوند.

## ۴.۲.۲ خود رمز کننده حذف نویز

نوع دیگری از خود رمز کننده که می‌توان از آن برای حذف نویز در داده استفاده کرد را به اصطلاح خودرمز کننده حذف نویز<sup>۱۸</sup> نام دارد. تفاوت این مدل با حالت کلی خود رمز کننده‌ها در فرایند آموزش مدل است. در این مدل داده ورودی ابتدا با استفاده از یک تولید کننده نویز، نویزی می‌شود. سپس به مدل خودرمز کننده داده می‌شود. شبکه نهایی باید بتواند نویز اضافه شده با تصاویر را حذف کند. برای انجام این کار یک راه ساده، تعریف تابع خطا به صورت مقایسه خروجی مدل و ورودی اصلی بدون نویز است. شبکه باید تلاش کند تا اختلاف تصویر باز سازی شده و تصویر اصلی را به حداقل برساند. پس از آموزش این مدل، شبکه قادر خواهد بود تا هرگونه ناهنجاری در داده که در اینجا همان نویز موجود در دادگان است را حذف کند. سپس با مقایسه مقدار خروجی و ورودی مکان‌هایی که تفاوت زیادی با یکدیگر دارند به احتمال تعلق به دسته ناهنجاری در آنها زیاد است.

## ۵.۲.۲ خودرمزکننده RDA

خودرمزکننده‌هایی که تا کنون معرفی شدند، در مرحله آموزش مدل تنها از دادگان عادی و بدون ناهنجاری استفاده می‌کردند و دادگان ناهنجار تنها زمان آزمون مدل استفاده می‌شدند. حال اگر بخواهیم دادگان ناهنجار را نیز در فرآیند آموزش مدل دخیل کنیم باید روش جدیدی را معرفی کنیم. خودرمز کننده مقاوم<sup>۱۹</sup> درواقع از ایده تجزیه و تحلیل مؤلفه بنیادی مقاوم<sup>۲۰</sup> برگرفته شده است. در روش تجزیه و تحلیل مؤلفه بنیادی مقاوم، دادگان ورودی با استفاده از دو ماتریس مرتبه پایین<sup>۲۱</sup> و خلوت<sup>۲۲</sup> نمایش داده می‌شوند.

$$X = L + S \quad (6.2)$$

<sup>14</sup>Sparse AutoEncoder (SAE)

<sup>15</sup>Sparse

<sup>16</sup>Regulizer

<sup>17</sup>L1-Rgulizer

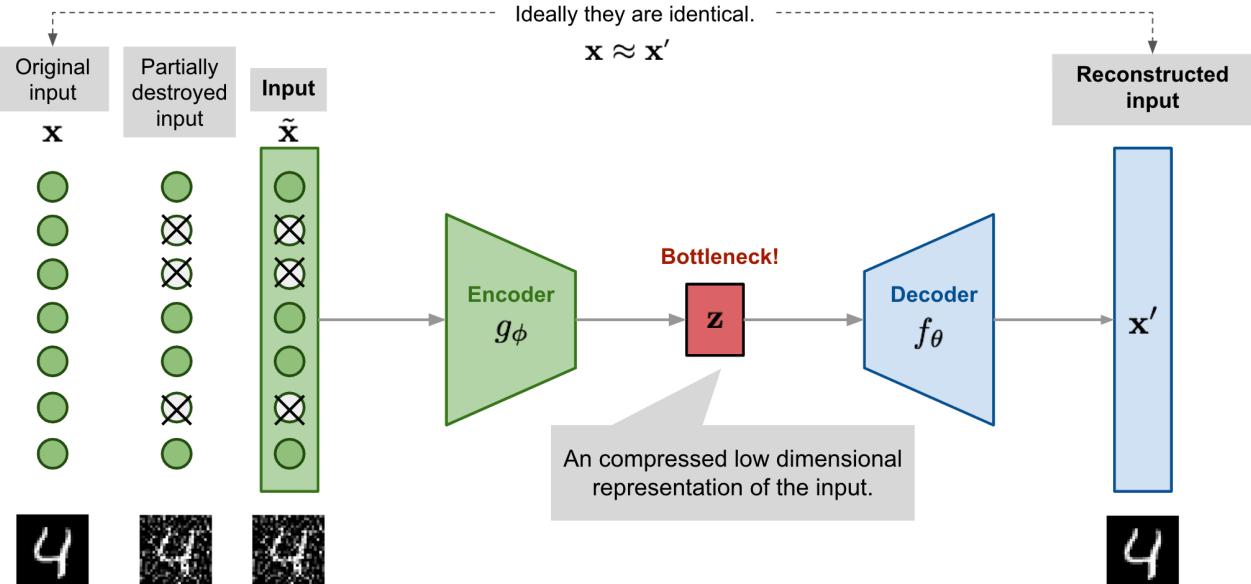
<sup>18</sup>Denoising Auto Encoder

<sup>19</sup>Robust Deep AutoEncoder

<sup>20</sup>Robust PCA

<sup>21</sup>Low rank

<sup>22</sup>Sparse



شکل ۷.۲: مدل خود رمز کننده حذف نویز

که در اینجا  $L$  نمایش داده ورودی در ابعاد پایین تر است و  $S$  قسمتی از دادگان است که نمی تواند توسط  $L$  به خوبی نمایش داده شود. این دوماتریس تحت شرط بهینه سازی وتابع هدف زیر آموزش داده می شوند .<sup>۲۳</sup>

$$\|X - L - S\|_F^2 = 0 \quad (7.2)$$

$$\min_{L,S} \|L\|_* + \lambda \|S\|_1 \quad (8.2)$$

این روش نیز سعی دارد دادگان ورودی را به استفاده از دو ماتریس نمایش دهد که ماتریس اول بازنمایی بدست آمده توسط خودرمز کننده است و قسمت دوم نمایانگر ناهنجاری هایی است که نمی توانند توسط خودرمز کننده به خوبی بازنمایی شوند.

$$X = L_D + S \quad (9.2)$$

اگر رمز کننده و رمزگشا را به عنوان دو تابع  $f$  و  $g$  در نظر بگیریم، معادل بهینه سازی مدل به صورت زیر خواهد بود.

$$\min_{\theta} \|L_D - G_\theta(F_\theta(L_D))\|_2 + \lambda \|S\|_1 \quad (10.2)$$

که شرایط زیر باید در فرایند بهینه سازی صدق کند:

$$X - L_D - S = 0 \quad (11.2)$$

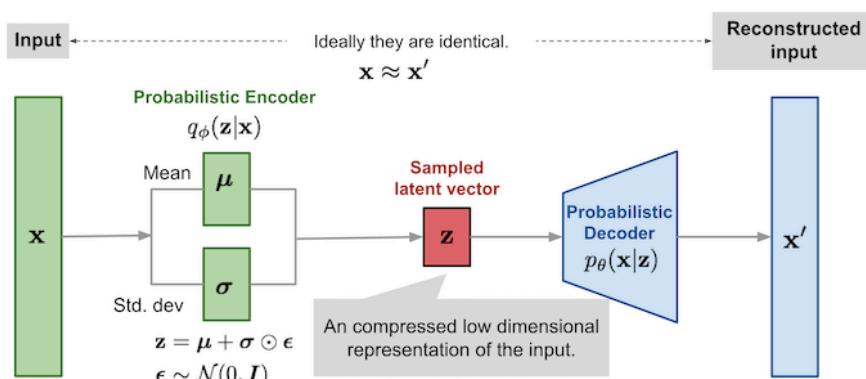
فرایند امتیاز دهی به ناهنجاری در این نوع خودرمز کننده مشابه روش اصلی خواهد بود. در اینجا  $S$  در واقع همان ناهنجاری های موجود در دادگان هستند که پس از تکمیل فرایند آموزش می توانیم از آن استفاده کنیم. این روش در مقایسه با روش سنتی در کاربرد تشخیص ناهنجاری حدود ۷۰ درصد بهتر عمل کرده است [۳۰].

<sup>۲۳</sup> در اینجا  $\|.\|_F$  نرم و  $\|.\|_*$  جمع مقادیر یکتا (singular value) است.

## ۶.۲.۲ خود رمز کننده VAE

مشکل که خود رمز کننده هایی که تا کنون معرفی کردیم در این است که نگاشت دادگان به فضای باقیمانده به صورت قطعی صورت می گیرد. یعنی هر نقطه از فضای ورودی به یک نقطه معین از فضای باقیمانده نگاشته می شود. از طرف دیگر اگر یک نقطه را به صورت تصادفی در فضای باقیمانده، مانند  $\hat{z}$  را در نظر بگیریم، نمی توان به طور قطع گفت که این نقطه به کدام دسته از نقاط تعلق خواهد گرفت. در واقع خود رمز کننده هایی که تا کنون مطالعه کردیم به خوبی دادگان ورودی را به فضایی با ابعاد دیگر نگاشت می کردند اما در هیچ یک از این روش ها ما اختیاری برای کنترل روند و نحوه این نگاشت نداشتمیم. انواع مختلف این رمز کننده ها نیز بسته به نیاز، نگاشت های گوناگونی را در اختیار ما قرار می دادند تا مناسب کاربرد انتخاب شده باشند. برای اینکه در طی فرایند یادگیری ما بر روی نحوه نگاش دادگان به فضای باقیمانده کنترل داشته باشیم، نوع دیگری از خود رمز کننده ها تحت عنوان خود رمز کننده <sup>۲۴</sup>VAE معرفی شده است [؟]. در این روش بجای یادگیری نگاشت گسسته و قطعی دادگان به فضای باقیمانده، سعی می شود توزیع دادگان در فضای باقیمانده یاد گرفته شود که در این صورت دادگان در این فضا توضیع پیوسته ای خواهد داشت و عمل درون یابی نقاط در این فضا کار راحت تری خواهد بود.

در این روش بجای تلاش برای کمینه کردن اختلاف ورودی مدل با خروجی بازسازی شده توسط مدل، سعی می شود تا احتمال درستنمایی نهایی <sup>۲۵</sup> حداقل شود. معادل تابع بهینه سازی این مدل به صورت زیر تعریف می شود.



شکل ۸.۲ مدل خود رمز کننده variational

$$\log(p(x)) \geq \log(p(x)) - KL(q_\phi(z|x)||p(z)) \quad (12.2)$$

$$\log(p(x)) - KL(q_\phi(z|x)||p(z)) = E_{z \sim q_\phi(x)} \log P_\phi(x|z) - KL(q_\phi(z|x)||p(z)) \quad (13.2)$$

$$\text{maximize } E_{z \sim q_\phi(x)} \log P_\phi(x|z) - KL(q_\phi(z|x)||p(z)) \quad (14.2)$$

<sup>24</sup>Variational AutoEncoder

<sup>25</sup>Marginal likelihood

در معادله (۱۴.۲) قسمت اول برای حداکثر کردن احتمال داده باز سازی شده است. قسمت دوم که در واقع می‌توان آن را به عنوان تنظیم کننده معادله درنظر گرفت، تلاش می‌کند تا توزیع دادگان در فضای بازنمایی  $\mathcal{Z}$  بسیار مشابه توزیع دادگان ورودی باشند. بنابراین بازنمایی دادگان در فضای باقیمانده بر خلاف مدل پایه به صورت غیر قطعی<sup>۲۶</sup> خواهد بود. همچنین دادگان بازسازی شده و همچنین امتیاز ناهنجاری برای دادگان نیز غیر قطعی و به صورت احتمال خواهد بود.

## ۷.۲.۲ شبکه‌های مولد رقابتی (GAN)

شبکه‌های مولد رقابتی<sup>۲۷</sup> از دو قسمت اصلی تشکیل شده‌اند که به صورت رقابتی با یکدیگر آموزش می‌بینند. هر یک از این دو قسمت، سعی دارند عملکرد طرف مقابل را با بالا بردن کیفیت کار خود به چالش بکشند. بخش اول این مدل که مول<sup>۲۸</sup> نام دارد، مسئولیت تولید داده مصنوعی را بر عهده دارد. این قسمت با گرفتن یک بردار ورودی از فضای باقیمانده، داده‌ای مصنوعی را تولید می‌کند. خروجی این قسمت به همراه یک نمونه از دادگان آموزش برای مقایسه و داوری جهت تشخیص مصنوعی و یا حقیقی بودن به قسمت دوم مدل که تصمیم گیرنده<sup>۲۹</sup> نام دارد وارد می‌شوند. بخش دوم باید بتواند به داده حقیقی که از دادگان آموزش دریافت کرده است برچسب حقیقی و به داده تولید شده توسط بخش مولد برچسب مصنوعی بودن را اختصاص دهد. آموزش این مدل‌ها به صورت نوبتی صورت می‌گیرد و با شروع از بخش دوم، وزن‌ها در بخش دیگر ثابت می‌مانند و پس از چند مرحله که عملکرد این قسمت بهبود یافت، تغییر وزن‌ها در آن بخش متوقف شده و وزن‌های بخش دیگر آموزش می‌بینند و پس از بهبود عملکرد قسمت بعدی این چرخه ادامه پیدا می‌کند. تابع خطای مورد استفاده در مدل‌های مولد پایه به صورت زیر است.

$$\min_G \max_D V(D, G) = E_{X \sim p_{data}(x)}[\log D(x)] + E_{z \sim p_z(z)}[\log(1 - D(G(z)))] \quad (15.2)$$

برای استفاده از این مدل در تشخیص ناهنجاری، استفاده از تابع خطای تصمیم گیرنده به عنوان تابع امتیاز ناهنجاری می‌تواند مفید باشد. در اینصورت، تابع تصمیم گیرنده  $D(X)$  وظیفه نگاشت دادگان به فضای تشخیص ناهنجاری را بر عهده دارد و تابع خطای این قسمت از مدل که به صورت زیر تعریف می‌شود به عنوان تابع امتیاز ناهنجاری بکار خواهد رفت.

$$d(x) = \log(1 - D(X)) \quad (16.2)$$

میزان آستانه تصمیم گیری  $\delta$  نیز می‌تواند با استفاده از آزمون و خطای و یا با استفاده از منحنی حساسیت و دقت تعیین گردد.

برای اینکه بتوانیم از شبکه مولد نیز در این مسئله کمک بگیریم، می‌توانیم در فرایند آموزش دادگان، بجای انتخاب تصادفی یک نقطه از فضای  $\mathcal{Z}$  به عنوان ورودی شبکه مولد، با استفاده از یک رمز کننده دادگان ورودی را ابتدا به رمز کننده بدھیم تا بازنمایی دادگان در فضای باقیمانده بدست آید و سپس این داده را به عنوان ورودی به شبکه مولد بدھیم تا با این بازنمایی اقدام به تولید داده مصنوعی کند. چیزی که در اینجا توقع داریم این است که داده تولید شده توسط تابع مولد، بسیار شبیه به داده ورودی رمز کننده باشد. در این صورت تابع بهینه سازی مدل به صورت زیر خواهد بود.

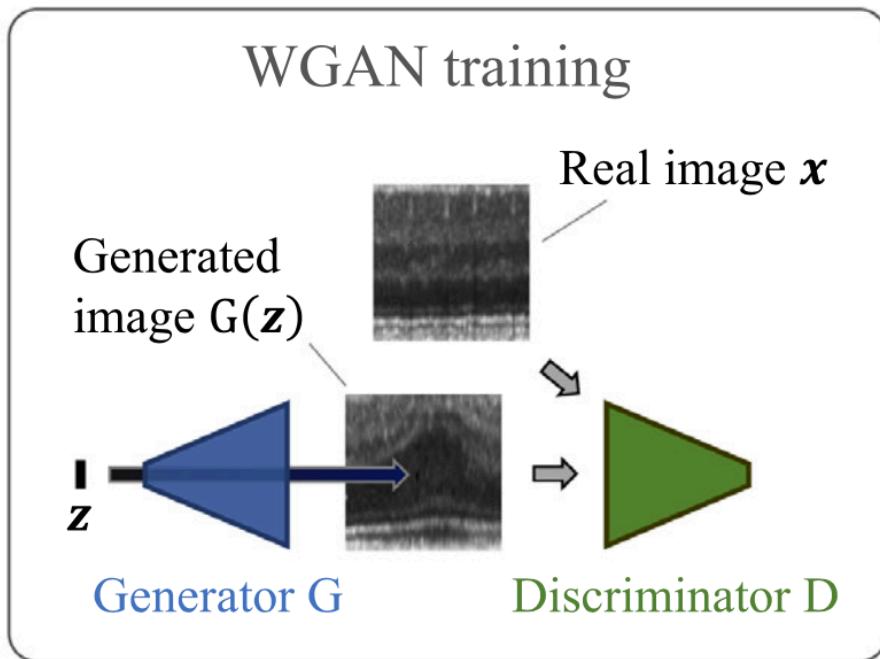
$$\min_\theta ||G(E(X, \theta)) - X|| + \lambda \log(1 - D(G(E(X, \theta)))) \quad (17.2)$$

<sup>26</sup>Stochastic

<sup>27</sup>Generative Adversarial Networks

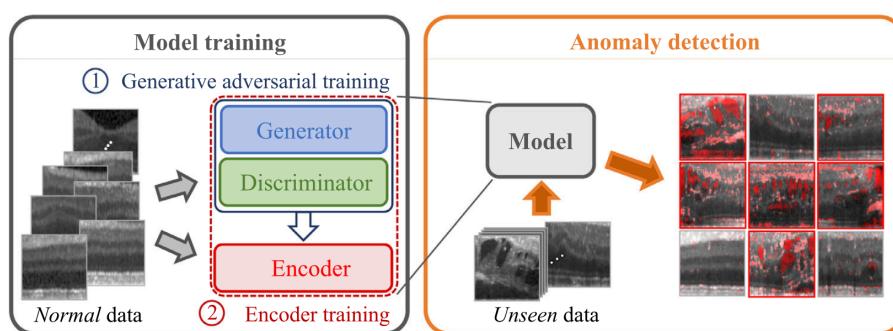
<sup>28</sup>Generator

<sup>29</sup>Discriminator



شکل ۹.۲: شبکه مولد رقابتی

در این معادله پارامتر  $\lambda$  یک ابر پارامتر مدل است که به صورت دستی تعیین می شود. این روش در سال ۲۰۱۷ توسط چلگ و همکاران تحت عنوان AnoGan معرفی شد که برای آشکار سازی ناهنجاری های در تصاویر گرفته شده از قرنیه چشم <sup>۳۰</sup> برای تشخیص بیماری چشم مورد استفاده قرار گرفته است [۲۳]. مدل بهبود یافته این روش که با نام f-AnoGan توسط همین پژوهشگران معرفی شده است، با جایگذاری روند نگاشت دادگان به فضای باقیمانده با یک رمز کننده از پیش آموزش دیده، سرعت محاسبات مدل را بهبود دادند [۲۲].



شکل ۱۰.۲: نمایش نحوه آموزش مدل [۲۲]

روش دیگری که از رویکرد شبکه های مولد استفاده می کند، GANomaly نام دارد. این روش با هدف تشخیص اشیاء ممنوعه در تصاویر گرفته شده با اشعه ایکس در خطوط کنترل وسایل توسعه داده شده است که عملکرد بهتری نسبت به روش AnoGan داشته است [۲].

<sup>30</sup>OCT

## ۸.۲.۲ مدل‌های جریانی

مدلهای جریانی<sup>۳۱</sup> مشابه خود رمز کننده VAE سعی می‌کنند تا توزیع دادگان ورودی را بیاموزند. در این رویکرد، سعی می‌شود تا با استفاده از یک دنباله از توابع مبدل معکوس پذیر که دادگان را از فضای باقیمانده به فضای ورودی نگاشت می‌کنند، توزیع دادگان آموخته شود. یکی از ایراداتی که بر خودرمز کننده VAE در یادگیری توزیع دادگان وارد است، در نظر گرفتن توزیع مانند گوسی برای دادگان است.

---

<sup>31</sup>Flow based models

### فصل ۳

## بررسی کارهای انجام شده

حال که به انواع مختلف روش‌های پایه‌ای آشناسدیم، می‌توانیم به استفاده از این روش‌ها در کاربردهای مختلف بپردازیم. اگر دادگان ما به صورت تصویر، صوت و یا ویدیو باشند، با تغییر لایه‌های کاملاً متصل به شبکه‌های کانولوشنی می‌توانیم از این عماری برای این کاربردها استفاده کنیم. همچنین برای دادگان دنباله‌ای مانند متن، سری‌های زمان و غیره نیز می‌توانیم با جایگذاری شبکه‌های بازگشتی به جای شبکه کاملاً متصل از این روش‌ها استفاده کنیم.

جدول ۱.۳: الگوریتم‌های عمیق مورد استفاده در تشخیص ناهنجاری

| روشهای عمیق معروف برای تشخیص ناهنجاری |                        |                                |
|---------------------------------------|------------------------|--------------------------------|
| نام مدل                               | مقاله مرجع             | ساختار عمیق مورد استفاده       |
| RDA                                   | ژائو و همکاران [۳۰]    | خود رمنگار                     |
| AnoGAN                                | چگل و همکاران [۲۲]     | شبکه مولد به همراه خود رمنگار  |
| f-AnoGan                              | چگل و همکاران [۲۲]     | شبکه مولد به همراه خود رمنگار  |
| LSA                                   | آباتی و همکاران [۱]    | خود رمنگار                     |
| ALAD                                  | زناتی و همکاران [۲۸]   | مدل مولد دوجهته                |
| GANomaly                              | آکای و همکاران [۲]     | خودرمنگار به همراه مدل مولد    |
| FFP                                   | لیو و همکاران [۱۲]     | مدل مولد                       |
| EBGAN                                 | زناتی و همکاران [۲۷]   | مدل مولد                       |
| GT                                    | گولان و همکاران [۱۰]   | استفاده از ساختارهای پایه عمیق |
| E3Outlier                             | پانگ و همکاران [۱۶]    | استفاده از ساختارهای پایه عمیق |
| REPEN                                 | ژائو و همکاران [۳۰]    | استفاده از ساختارهای پایه عمیق |
| RDP                                   | وانگ و همکاران [۲۶]    | استفاده از ساختارهای پایه عمیق |
| AE-OSVM                               | نگوین و همکاران [۱۵]   | ترکیب خودرمنگار و روش سنتی     |
| OC-NN                                 | چالاپاتی و همکاران [۶] | استفاده از ساختارهای پایه عمیق |
| Deep SVDD                             | روف و همکاران [۱۹]     | استفاده از ساختارهای پایه عمیق |
| Deep SAD                              | روف و همکاران [۲۰]     | ترکیب خود رمنگار و روش سنتی    |
| DAGMM                                 | زونگ و همکاران [۳۱]    | استفاده از ساختارهای پایه عمیق |
| MIL                                   | سلطانی و همکاران [۲۵]  | خود رمنگار                     |
| DevNet                                | پانگ و همکاران [۱۷]    | خود رمنگار                     |
| ALOCC                                 | سیکرو و همکاران [۲۱]   | خود رمنگار                     |
| OCAN                                  | ژنگ و همکاران [۲۹]     | استفاده از ساختارهای پایه عمیق |
| FenceGAN                              | ژائو و همکاران [۱۴]    | شبکه مولد                      |
| OCGAN                                 | پرا و همکاران [۱۸]     | شبکه مولد                      |
| SPADE                                 | کوهن و همکاران [۸]     | ساختارهای پایه عمیق            |

## فصل ۴

### کارهای آینده

همانطور که در فصل یک با اهمیت کاربرد روش‌های تشخیص ناهنجاری در حوزه‌های مختلف آشنا شدیم و در فصل دوم و سوم علاوه بر مطالعه روش‌های موجود و مناسب برای مسئله تشخیص ناهنجاری، به بررسی کارهای انجام شده در این حوزه پرداختیم حال وقت آن رسیده که مسائل و چالش‌های باز این حوزه را مرور کنیم.

#### ۱.۴ مسائل باز و کارهای قابل انجام

در مسائل تشخیص ناهنجاری یکی از چالش‌های مهم، در دسترس نبودن دادگان برچسب خورده کافی و مناسب یادگیری است. با توجه به اینکه ناهنجاری‌ها ذاتاً به ندرت اتفاق می‌افتد و همچنین مفهوم ناهنجاری در کاربردهای گوناگون متفاوت است، استفاده از روش‌های با ناظر در این مورد مسئله‌ای چالش برانگیز است. یکی از روش‌های پرکاربرد در تشخیص ناهنجاری، یادگیری بازنمایی دادگان عادی است که در فصل سوم به برخی از آنها پرداختیم. در استفاده از این روش‌ها، این احتمال وجود دارد که دادگان آموزش ممکن است دارای خطای خطا باشند که این مورد ممکن است در فرایند یادگیری تاثیر بگذارد. همچنین در بسیاری از کاربردها مرز مشخص و دقیقی میان دادگان عادی و ناهنجار وجود ندارد. از این رو یافتن روش‌هایی که در مقابل خطای مقاوم باشند یکی از مسائل و چالش‌های بازی در این حوزه است. برای مقابله با چالش کمبود دادگان ناهنجار، ابداع روش‌های داده‌افزایی و بازنمایی دادگان که نیاز به تعداد کمی داده داشته باشند نیز یکی از مسائل باز است.

#### ۲.۴ موضوع پیشنهادی برای پایان نامه

با توجه به کاربرد وسیع مسئله تشخیص ناهنجاری در حوزه پزشکی و مشکل کمبود دادگان برچسب خورده به دلیل چالش‌هایی که در این حوزه وجود دارد، استفاده از روش‌های تشخیص ناهنجاری در این حوزه بسیار مناسب است. در پردازش تصاویر پزشکی به دلیل منحصر به فرد بودن بافت بدن اشخاص مختلف و همچنین نادر بودن بیماری‌ها در میان افراد می‌توان از دید مسئله تشخیص ناهنجاری به وجود توده‌های سرطانی در تصاویر پزشکی نگاه کرد و به بررسی مسئله از این دید پرداخت که می‌تواند به عنوان پیشنهادی برای پروژه پایانی بررسی شود.

# کتاب نامه

- [1] Abati, Davide, Porrello, Angelo, Calderara, Simone, and Cucchiara, Rita. Latent Space Autoregression for Novelty Detection. In *Proceedings of the IEEE/CVF International Conference on Computer Vision and Pattern Recognition*, 2019.
- [2] Akcay, Samet, Atapour-Abarghouei, Amir, and Breckon, Toby P. Ganomaly: Semi-supervised anomaly detection via adversarial training. In *Asian Conference on Computer Vision*, pages 622–637. Springer, 2018.
- [3] Bhuvaneshwari, M., Kanaga, E. Grace Mary, Anitha, J., Raimond, Kumudha, and George, S. Thomas. Chapter 7 - a comprehensive review on deep learning techniques for a bci-based communication system. In N, Pradeep, Kautish, Sandeep, and Peng, Sheng-Lung, editors, *Demystifying Big Data, Machine Learning, and Deep Learning for Healthcare Analytics*, pages 131–157. Academic Press, 2021.
- [4] Breunig, Markus M., Kriegel, Hans-Peter, Ng, Raymond T., and Sander, Jörg. Lof: Identifying density-based local outliers. In *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, SIGMOD '00, pages 93–104, New York, NY, USA, 2000. Association for Computing Machinery.
- [5] Chalapathy, Raghavendra and Chawla, Sanjay. Deep learning for anomaly detection: A survey. 01 2019.
- [6] Chalapathy, Raghavendra, Menon, Aditya Krishna, and Chawla, Sanjay. Anomaly detection using one-class neural networks. *arXiv preprint arXiv:1802.06360*, 2018.
- [7] Chandola, Varun, Banerjee, Arindam, and Kumar, Vipin. Anomaly detection: A survey. *ACM Comput. Surv.*, 41(3), jul 2009.
- [8] Cohen, Niv and Hoshen, Yedid. Sub-image anomaly detection with deep pyramid correspondences. *CoRR*, abs/2005.02357, 2020.
- [9] Ehret, Thibaud, Davy, Axel, Morel, Jean-Michel, and Delbracio, Mauricio. Image anomalies: A review and synthesis of detection methods. *Journal of Mathematical Imaging and Vision*, 61(5):710–743, 2019.
- [10] Golan, Izhak and El-Yaniv, Ran. Deep anomaly detection using geometric transformations. In Bengio, S., Wallach, H., Larochelle, H., Grauman, K., Cesa-Bianchi, N., and Garnett, R., editors, *Advances in Neural Information Processing Systems*, volume 31. Curran Associates, Inc., 2018.
- [11] Grubbs, Frank E. Procedures for detecting outlying observations in samples. *Technometrics*, 11:1–21, 1969.

- [12] Liu, Wen, Luo, Weixin, Lian, Dongze, and Gao, Shenghua. Future frame prediction for anomaly detection - a new baseline. In *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 6536–6545, 2018.
- [13] Murugan, B.S., Elhoseny, Mohamed, Shankar, K., and Uthayakumar, J. Region-based scalable smart system for anomaly detection in pedestrian walkways. *Comput. Electr. Eng.*, 75(C):146–160, may 2019.
- [14] Ngo, Cuong Phuc, Winarto, Amadeus Aristo, Kou, Connie Khor Li, Park, Sojeong, Akram, Farhan, and Lee, Hwee Kuan. Fence gan: Towards better anomaly detection. 2019.
- [15] Nguyen, Minh-Nghia and Vien, Ngo. Scalable and interpretable one-class svms with deep learning and random fourier features. 04 2018.
- [16] Pang, Guansong, Cao, Longbing, Chen, Ling, and Liu, Huan. Learning representations of ultrahigh-dimensional data for random distance-based outlier detection. In *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery amp; Data Mining*, KDD ’18, pages 2041–2050, New York, NY, USA, 2018. Association for Computing Machinery.
- [17] Pang, Guansong, Shen, Chunhua, and van den Hengel, Anton. Deep anomaly detection with deviation networks. In *Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining*, pages 353–362, 2019.
- [18] Perera, Pramuditha, Nallapati, Ramesh, and Xiang, Bing. Ogan: One-class novelty detection using gans with constrained latent representations. In *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2893–2901, 2019.
- [19] Ruff, Lukas, Vandermeulen, Robert, Goernitz, Nico, Deecke, Lucas, Siddiqui, Shoaib Ahmed, Binder, Alexander, Müller, Emmanuel, and Kloft, Marius. Deep one-class classification. In Dy, Jennifer and Krause, Andreas, editors, *Proceedings of the 35th International Conference on Machine Learning*, volume 80 of *Proceedings of Machine Learning Research*, pages 4393–4402. PMLR, 10–15 Jul 2018.
- [20] Ruff, Lukas, Vandermeulen, Robert A., Görnitz, Nico, Binder, Alexander, Müller, Emmanuel, Müller, Klaus-Robert, and Kloft, Marius. Deep semi-supervised anomaly detection. In *International Conference on Learning Representations*, 2020.
- [21] Sabokrou, Mohammad, Khalooei, Mohammad, Fathy, Mahmood, and Adeli, Ehsan. Adversarially learned one-class classifier for novelty detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 3379–3388, 2018.
- [22] Schlegl, Thomas, Seeböck, Philipp, Waldstein, Sebastian M., Langs, Georg, and Schmidt-Erfurth, Ursula. f-anogan: Fast unsupervised anomaly detection with generative adversarial networks. *Medical Image Analysis*, 54:30–44, 2019.
- [23] Schlegl, Thomas, Seeböck, Philipp, Waldstein, Sebastian M., Schmidt-Erfurth, Ursula, and Langs, Georg. Unsupervised anomaly detection with generative adversarial networks to guide marker discovery. In Niethammer, Marc, Styner, Martin, Aylward, Stephen, Zhu, Hongtu, Oguz, Ipek, Yap, Pew-Thian, and Shen, Dinggang, editors, *Information Processing in Medical Imaging*, pages 146–157, Cham, 2017. Springer International Publishing.

- [24] Schölkopf, Bernhard, Williamson, Robert, Smola, Alex, Shawe-Taylor, John, and Platt, John. Support vector method for novelty detection. In *Proceedings of the 12th International Conference on Neural Information Processing Systems*, NIPS'99, pages 582–588, Cambridge, MA, USA, 1999. MIT Press.
- [25] Sultani, Waqas, Chen, Chen, and Shah, Mubarak. Real-world anomaly detection in surveillance videos. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2018.
- [26] Wang, Hu, Pang, Guansong, Shen, Chunhua, and Ma, Congbo. Unsupervised representation learning by predicting random distances. In *Proceedings of the Twenty-Ninth International Joint Conference on Artificial Intelligence*, IJCAI'20, 2021.
- [27] Zenati, Houssam, Foo, Chuan Sheng, Lecouat, Bruno, Manek, Gaurav, and Chandrasekhar, Vijay Ramaseshan. Efficient gan-based anomaly detection. 2018.
- [28] Zenati, Houssam, Romain, Manon, Foo, Chuan Sheng, Lecouat, Bruno, and Chandrasekhar, Vijay R. Adversarially learned anomaly detection. *2018 IEEE International Conference on Data Mining (ICDM)*, pages 727–736, 2018.
- [29] Zheng, Panpan, Yuan, Shuhan, Wu, Xintao, Li, Jun, and Lu, Aidong. One-class adversarial nets for fraud detection. *Proceedings of the AAAI Conference on Artificial Intelligence*, 33, 03 2018.
- [30] Zhou, Chong and Paffenroth, Randy C. Anomaly detection with robust deep autoencoders. In *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, KDD '17, pages 665–674, New York, NY, USA, 2017. Association for Computing Machinery.
- [31] Zong, Bo, Song, Qi, Min, Martin Renqiang, Cheng, Wei, Lumezanu, Cristian, ki Cho, Dae, and Chen, Haifeng. Deep autoencoding gaussian mixture model for unsupervised anomaly detection. In *ICLR*, 2018.

# **Abstract**

Anomaly detection is a well studied problem in various fields of science.



Department of computer engineering

# **Deep learning for anomaly detection**

Master seminar report  
Computer engineering - Artificial intelligence and  
robotics

Student name:  
Ali Naderi Parizi

Professor:  
Dr. Mohsen Soryani

April 2022